


Porta de correr: Ima perto fechada



Porta fechada } Ima perto = O ima magnetiza as lâminas com isso elas se unem e o circuito fecha (passa corrente)

Porta aberta } Ima longe = Circuito aberto não passa corrente


→ Se há corrente "circulando" então porta fechada se não porta aberta

Hardware:

Esp32 ✓

Reed switch

Jst sh1



fonte de energia para a corrente Jst sh1 4 vias 1,25 mm

• Initial - retrieval - $K = 10$:

↳ Define o número inicial de documentos a serem recuperados pelo retriever (o que busca a similaridade) (BAAI-bge-reranker-v2-m3)

Pergunta usuário



Busca vetorial (embedding)



Retorna 10 documentos candidatos (10 chunks mais relevantes)

• Min - cross - encoder - score = 0.15

↳ É basicamente o score mínimo de encoder. Compara a relevância dos documentos encontrados com a query (pergunta do usuário)

↳ 1º acontece o re-ranking do cross-encoder e depois sai o score

↳ Modelo de re-ranking utilizado: bge-reranker-v2-m3

1º) PDFs (PDF ----> banco vetorial)

PDFs (PDF-DIR)



Extração de texto (PyMuPDF)



Limpeza de texto (clean-text-content)



Deteção de tabelas (extract-tables)



Chunking de documentos

RecursiveCharacterTextSplitter

↳ Algoritmo de segmentação de texto ("quebra" o texto usando hierarquia de separadores)



Geração de embeddings
(multilingual-e5-large)



Armazenamento vetorial

~~Chroma~~ (Chroma BD)

2º Busca (retrieval)

Query do usuário



expand - query()



Vector-search (compara vetores usando
(query, doc) de similaridade e re-
torna os K documentos



Documentos candidatos mais próximos



Cross-encoder Re-ranking (bge-reranker)



Score de relevância

- filtro 1: Score > 0.15
- filtro 2: Um chunk precisa ter pelo menos 20% do melhor resultado



documentos mais relevantes

3º) Geração de respostas:

Documentos relevantes



Construção do contexto

(contexto = chunks de texto mais relevantes com base na pergunta)

(número máximo de token = 1500)



Prompt final

(Prompt-final = Instruções + Contexto + pergunta)

↳ system prompt




LLM (Meta-Llama-3.1-8B)



Resposta

Extra IA

- Precisa de um servidor para pegar a pergunta do usuário (na interface Unity), ela ser processada pelo RAG e a resposta do RAG enviada como resposta para o Unity



- Por que usar o FastAPI no lugar de Flask ou Django? Porque ele é o intermediário (na dúvida sempre escolha o intermediário). O flask é muito básico e síncrono e o Django lento e complexo, Já o fastAPI é rápido e assíncrono (não precisa terminar de processar alguma pergunta para começar a processar outra)

- Por que usar WebSocket no lugar do protocolo HTTP? Na verdade o websocket é uma gambiarra do HTTP (handshaking) (é tipo o cavalo de troia ele se disfarça de HTTP (a maioria dos sites e essas coisas estão configuradas para HTTP/HTTPS), mas tirando esse fato o websocket não utiliza a arquitetura cliente-servidor (melhor para coisas em tempo-real)